Análise de compartilhamento de bicicletas Cyclistic

Jander

14-04-2024

Estudo de caso Cyclistic

Cenário Cyclistic: Um programa de compartilhamento de bicicletas que conta com mais de 5.800 bicicletas e 600 estações de compartilhamento. A Cyclistic se diferencia por também oferecer bicicletas reclináveis, triciclos manuais e bicicletas de carga, tornando o compartilhamento de mais inclusivo para pessoas com deficiência e ciclistas que não podem usar uma bicicleta padrão de duas rodas. A maioria dos ciclistas opta por bicicletas tradicionais; cerca de 8% dos motociclistas usam as opções assistivas. Os usuários da Cyclistic são mais propensos a pedalar por lazer, mas cerca de 30% utilizam as bicicletas para se deslocarem ao trabalho diariamente.

Os clientes que adquirem passes de viagem única ou de dia inteiro são chamados de passageiros casuais.

Lily Moreno (Diretora de Marketing) estabeleceu um objetivo claro: criar estratégias de marketing destinadas a converter passageiros casuais em membros anuais. Para fazer isso, no entanto, a equipe de analistas de marketing precisa entender melhor como os membros anuais e os passageiros casuais diferem, por que os passageiros casuais iriam querer adquirir um plano e como a mídia digital poderia afetar suas táticas de marketing.

Perguntar:

Partes Interessadas Lily Moreno: Diretora de marketing e gerente. Responsável pelo desenvolvimento de campanhas e iniciativas de promoção do programa de compartilhamento de bicicletas.

Equipe de análise de marketing da Cyclistic: Uma equipe de analistas de dados responsáveis por coletar, analisar e relatar dados que ajudam a orientar a estratégia de marketing da Cyclistic.

Equipe executiva da Cyclistic: A equipe executiva notoriamente detalhista decidirá se aprova o programa de marketing recomendado.

Tarefa de negócios

Entender como os membros anuais e casuais se diferem.

Qual problema estou tentando resolver?

Por que os passageiros casuais iriam querer adquirir um plano e como a mídia digital poderia afetar táticas de marketing.

Preparar: Onde os dados estão localizados? Os arquivos estão sãos em um servidor remoto (aqui) e fornecido por Motivate International Inc.

Foram feitos os downloads dos arquivos Cyclistic em formato csv e armazenados em meu desktop organizados por data. Não foram identificados viéses de credibilidade.

Licença para uso dos dados:

https://ride.divvybikes.com/data-license-agreement

Processar: A ferramenta que escolhi no processamento dos dados foi R para colocar em prática o conteúdo ensinado no curso. Os arquivos contém dados do ano de 2022.

Carregando e instalando pacotes necessários

Antes de unir os arquivos em um único dataframe comparei o nome das colunas de todos os arquivos.

```
trips01 <- read.csv("202201-divvy-tripdata.csv")
trips02 <- read.csv("202203-divvy-tripdata.csv")
trips03 <- read.csv("202204-divvy-tripdata.csv")
trips04 <- read.csv("202204-divvy-tripdata.csv")
trips05 <- read.csv("202205-divvy-tripdata.csv")
trips06 <- read.csv("202206-divvy-tripdata.csv")
trips07 <- read.csv("202207-divvy-tripdata.csv")
trips08 <- read.csv("202208-divvy-tripdata.csv")
trips09 <- read.csv("202209-divvy-tripdata.csv")
trips10 <- read.csv("202210-divvy-tripdata.csv")
trips11 <- read.csv("202211-divvy-tripdata.csv")
trips12 <- read.csv("202212-divvy-tripdata.csv")</pre>
```

```
## [1] "ride_id" "rideable_type" "started_at"
## [4] "ended_at" "start_station_name" "start_station_id"
## [7] "end_station_name" "end_station_id" "start_lat"
## [10] "start_lng" "end_lat" "end_lng"
## [13] "member_casual"
```

colnames(trips02)

colnames(trips03)

```
colnames(trips04)
##
    [1] "ride_id"
                              "rideable_type"
                                                    "started_at"
    [4] "ended_at"
                              "start_station_name"
                                                   "start_station_id"
##
  [7] "end_station_name"
                              "end_station_id"
                                                    "start_lat"
## [10] "start_lng"
                              "end_lat"
                                                    "end_lng"
## [13] "member_casual"
colnames(trips05)
    [1] "ride_id"
                              "rideable_type"
                                                    "started at"
##
   [4] "ended at"
                              "start_station_name" "start_station_id"
## [7] "end_station_name"
                              "end_station_id"
                                                    "start_lat"
## [10] "start_lng"
                              "end lat"
                                                    "end_lng"
## [13] "member casual"
colnames(trips06)
    [1] "ride_id"
                              "rideable_type"
                                                    "started_at"
   [4] "ended_at"
                              "start_station_name"
                                                   "start_station_id"
   [7] "end station name"
                                                    "start lat"
                              "end station id"
## [10] "start_lng"
                              "end lat"
                                                    "end_lng"
## [13] "member casual"
colnames(trips07)
    [1] "ride_id"
##
                              "rideable_type"
                                                    "started_at"
    [4] "ended_at"
                              "start_station_name"
                                                   "start_station_id"
##
  [7] "end_station_name"
                              "end_station_id"
                                                    "start_lat"
## [10] "start_lng"
                              "end_lat"
                                                    "end_lng"
## [13] "member_casual"
colnames(trips08)
   [1] "ride_id"
                              "rideable_type"
                                                    "started_at"
##
   [4] "ended_at"
                              "start_station_name" "start_station_id"
  [7] "end_station_name"
                              "end_station_id"
                                                    "start_lat"
## [10] "start lng"
                              "end lat"
                                                    "end_lng"
## [13] "member casual"
colnames(trips09)
    [1] "ride_id"
                                                    "started_at"
##
                              "rideable_type"
##
    [4] "ended_at"
                              "start_station_name"
                                                   "start_station_id"
   [7] "end_station_name"
                              "end_station_id"
                                                    "start_lat"
## [10] "start_lng"
                              "end_lat"
                                                    "end_lng"
## [13] "member_casual"
```

```
colnames(trips10)
##
   [1] "ride_id"
                             "rideable_type"
                                                   "started_at"
   [4] "ended_at"
                             "start_station_name" "start_station_id"
## [7] "end_station_name"
                              "end_station_id"
                                                   "start_lat"
## [10] "start_lng"
                              "end_lat"
                                                   "end_lng"
## [13] "member_casual"
colnames(trips11)
                                                   "started_at"
   [1] "ride_id"
                             "rideable_type"
##
   [4] "ended at"
                              "start station name" "start station id"
                                                   "start_lat"
## [7] "end_station_name"
                             "end_station_id"
## [10] "start_lng"
                             "end lat"
                                                   "end_lng"
## [13] "member_casual"
colnames(trips12)
   [1] "ride_id"
                              "rideable_type"
                                                   "started_at"
##
   [4] "ended_at"
                             "start_station_name" "start_station_id"
## [7] "end_station_name"
                              "end_station_id"
                                                   "start_lat"
## [10] "start_lng"
                              "end_lat"
                                                   "end_lng"
## [13] "member_casual"
Unindo arquivos em um único dafa frame
all_trips <- list.files(path='C:/Users/jande/Documentos/Estudo de Caso/datasets/trip_files/divvy_tripda
  lapply(read_csv) %>%
  bind_rows
Data Cleaning e preparação para análise
# Nome de colunas
colnames(all_trips)
## [1] "ride_id"
                              "rideable_type"
                                                   "started_at"
   [4] "ended_at"
                              "start_station_name" "start_station_id"
## [7] "end_station_name"
                             "end_station_id"
                                                   "start_lat"
## [10] "start_lng"
                              "end_lat"
                                                   "end_lng"
## [13] "member_casual"
# Número de linhas
nrow(all_trips)
## [1] 5667717
# Dimensoes do df
dim(all_trips)
## [1] 5667717
```

13

```
head(all_trips)
## # A tibble: 6 x 13
    ride id
                     rideable_type started_at
                                                       ended at
    <chr>>
                     <chr>
                                   <dttm>
                                                       <dttm>
## 1 C2F7DD78E82EC875 electric_bike 2022-01-13 11:59:47 2022-01-13 12:02:44
## 2 A6CF8980A652D272 electric_bike 2022-01-10 08:41:56 2022-01-10 08:46:17
## 3 BD0F91DFF741C66D classic_bike 2022-01-25 04:53:40 2022-01-25 04:58:01
## 4 CBB80ED419105406 classic_bike 2022-01-04 00:18:04 2022-01-04 00:33:00
## 5 DDC963BFDDA51EEA classic bike 2022-01-20 01:31:10 2022-01-20 01:37:12
## 6 A39C6F6CC0586C0B classic_bike 2022-01-11 18:48:09 2022-01-11 18:51:31
## # i 9 more variables: start_station_name <chr>, start_station_id <chr>,
      end_station_name <chr>, end_station_id <chr>, start_lat <dbl>,
      start_lng <dbl>, end_lat <dbl>, end_lng <dbl>, member_casual <chr>
# Lista de colunas e tipos de dado
str(all_trips)
## spc_tbl_ [5,667,717 x 13] (S3: spec_tbl_df/tbl_df/tbl/data.frame)
## $ ride id
                       : chr [1:5667717] "C2F7DD78E82EC875" "A6CF8980A652D272" "BD0F91DFF741C66D" "CBB
## $ rideable_type
                       : chr [1:5667717] "electric_bike" "electric_bike" "classic_bike" "classic_bike"
                       : POSIXct[1:5667717], format: "2022-01-13 11:59:47" "2022-01-10 08:41:56" ...
## $ started at
                       : POSIXct[1:5667717], format: "2022-01-13 12:02:44" "2022-01-10 08:46:17" ...
## $ ended_at
## $ start_station_name: chr [1:5667717] "Glenwood Ave & Touhy Ave" "Glenwood Ave & Touhy Ave" "Sheffi
## $ start_station_id : chr [1:5667717] "525" "525" "TA1306000016" "KA1504000151" ...
## $ end_station_name : chr [1:5667717] "Clark St & Touhy Ave" "Clark St & Touhy Ave" "Greenview Ave
                       : chr [1:5667717] "RP-007" "RP-007" "TA1307000001" "TA1309000021" ...
## $ end_station_id
## $ start_lat
                       : num [1:5667717] 42 42 41.9 42 41.9 ...
                       : num [1:5667717] -87.7 -87.7 -87.7 -87.6 ...
## $ start_lng
## $ end_lat
                       : num [1:5667717] 42 42 41.9 42 41.9 ...
## $ end_lng
                       : num [1:5667717] -87.7 -87.7 -87.7 -87.7 -87.6 ...
## $ member_casual
                       : chr [1:5667717] "casual" "casual" "member" "casual" ...
##
   - attr(*, "spec")=
##
    .. cols(
##
         ride id = col character(),
##
        rideable_type = col_character(),
##
       started_at = col_datetime(format = ""),
    . .
##
       ended_at = col_datetime(format = ""),
##
    .. start_station_name = col_character(),
##
         start_station_id = col_character(),
##
         end_station_name = col_character(),
    . .
##
       end_station_id = col_character(),
##
       start_lat = col_double(),
##
         start_lng = col_double(),
     . .
##
         end_lat = col_double(),
    . .
##
         end_lng = col_double(),
##
         member_casual = col_character()
##
## - attr(*, "problems")=<externalptr>
```

6 primeiras linhas do df

resumo estatistico dos dados summary(all_trips)

```
##
      ride_id
                       rideable_type
                                             started_at
##
   Length: 5667717
                       Length: 5667717
                                                  :2022-01-01 00:00:05.00
##
   Class : character
                       Class : character
                                           1st Qu.:2022-05-28 19:21:05.00
   Mode :character
                       Mode :character
                                           Median :2022-07-22 15:03:59.00
                                                  :2022-07-20 07:21:18.74
##
                                          Mean
##
                                           3rd Qu.:2022-09-16 07:21:29.00
##
                                          Max.
                                                  :2022-12-31 23:59:26.00
##
##
       ended_at
                                     start_station_name start_station_id
##
   Min.
           :2022-01-01 00:01:48.00
                                     Length: 5667717
                                                         Length: 5667717
   1st Qu.:2022-05-28 19:43:07.00
                                     Class :character
                                                         Class : character
   Median :2022-07-22 15:24:44.00
                                     Mode :character
                                                         Mode : character
           :2022-07-20 07:40:45.33
##
   Mean
##
   3rd Qu.:2022-09-16 07:39:03.00
##
   Max. :2023-01-02 04:56:45.00
##
##
   end_station_name
                       end_station_id
                                             start_lat
                                                             start_lng
##
   Length: 5667717
                       Length: 5667717
                                          Min.
                                                 :41.64
                                                           Min. :-87.84
  Class : character
                       Class : character
                                           1st Qu.:41.88
                                                           1st Qu.:-87.66
##
   Mode :character
                       Mode :character
                                          Median :41.90
                                                           Median :-87.64
##
                                          Mean :41.90
                                                           Mean :-87.65
##
                                          3rd Qu.:41.93
                                                           3rd Qu.:-87.63
##
                                          Max.
                                                :45.64
                                                           Max.
                                                                 :-73.80
##
                       end_lng
##
       end lat
                                     member casual
##
   Min. : 0.00
                           :-88.14
                                     Length: 5667717
                    Min.
   1st Qu.:41.88
                    1st Qu.:-87.66
                                     Class : character
  Median :41.90
                    Median :-87.64
                                     Mode :character
##
                           :-87.65
## Mean :41.90
                    Mean
   3rd Qu.:41.93
                    3rd Qu.:-87.63
## Max.
           :42.37
                    Max.
                           : 0.00
                    NA's
## NA's
           :5858
                           :5858
```

Vizualisado colunas glimpse(all_trips)

```
## Rows: 5,667,717
## Columns: 13
                        <chr> "C2F7DD78E82EC875", "A6CF8980A652D272", "BD0F91DFF7~
## $ ride_id
## $ rideable_type
                        <chr> "electric_bike", "electric_bike", "classic_bike", "~
## $ started_at
                        <dttm> 2022-01-13 11:59:47, 2022-01-10 08:41:56, 2022-01-~
## $ ended_at
                        <dttm> 2022-01-13 12:02:44, 2022-01-10 08:46:17, 2022-01-~
## $ start_station_name <chr> "Glenwood Ave & Touhy Ave", "Glenwood Ave & Touhy A~
                        <chr> "525", "525", "TA1306000016", "KA1504000151", "TA13~
## $ start_station_id
                        <chr> "Clark St & Touhy Ave", "Clark St & Touhy Ave", "Gr~
## $ end_station_name
                        <chr> "RP-007", "RP-007", "TA1307000001", "TA1309000021",~
## $ end_station_id
## $ start_lat
                        <dbl> 42.01280, 42.01276, 41.92560, 41.98359, 41.87785, 4~
## $ start_lng
                        <dbl> -87.66591, -87.66597, -87.65371, -87.66915, -87.624~
                        <dbl> 42.01256, 42.01256, 41.92533, 41.96151, 41.88462, 4~
## $ end lat
                        <dbl> -87.67437, -87.67437, -87.66580, -87.67139, -87.627~
## $ end lng
```

```
<chr> "casual", "casual", "member", "casual", "member", "~
## $ member casual
Buscando possíveis erros de digitação
table(all_trips$member_casual)
##
## casual member
## 2322032 3345685
table(all_trips$rideable_type)
##
##
   classic_bike
                   docked_bike electric_bike
         2601214
                        177474
                                      2889029
##
Adicionando colunas para agregações futuras
all_trips$date <- as.Date(all_trips$started_at)</pre>
all_trips$month <- format(as.Date(all_trips$date), "%m")</pre>
all_trips$day <- format(as.Date(all_trips$date), "%d")</pre>
all_trips$year <- format(as.Date(all_trips$date), "%Y")</pre>
all_trips$day_of_week <- format.Date(as.Date(all_trips$date), "%A")
Verificando e removendo valores nulos
sum(is.na(all_trips))
## [1] 3463328
all_trips_v2 <- all_trips %>% drop_na()
sum(is.na(all_trips_v2))
## [1] 0
Adicionando duração do passeio em segundos
all_trips_v2$duracao_passeio <- difftime(all_trips_v2$ended_at, all_trips_v2$started_at)
Convertendo duracao_passeio para numérico
all_trips_v2$duracao_passeio <- as.numeric(as.character(all_trips_v2$duracao_passeio))
is.numeric(all_trips_v2$duracao_passeio)
```

Removendo duracao_passeio negativa

[1] TRUE

```
all_trips_v2 <- all_trips_v2[!(all_trips_v2$start_station_name == "HQ QR" | all_trips_v2$duracao_passei
Análise Descritiva
mean(all_trips_v2$duracao_passeio)
## [1] 1025.75
median(all_trips_v2$duracao_passeio)
## [1] 636
max(all_trips_v2$duracao_passeio)
## [1] 2061244
min(all_trips_v2$duracao_passeio)
## [1] 0
# As linhas acima podem ser resumidas utilizando "summary"
summary(all_trips_v2$duracao_passeio)
##
     Min. 1st Qu. Median
                              Mean 3rd Qu.
                                              Max.
##
         0
               363
                       636
                              1026
                                      1141 2061244
Comparando membros e usuários casuais
aggregate(all_trips_v2$duracao_passeio ~ all_trips_v2$member_casual, FUN = mean)
    all_trips_v2$member_casual all_trips_v2$duracao_passeio
##
## 1
                         casual
                                                    1439.586
## 2
                         member
                                                     747.104
aggregate(all_trips_v2$duracao_passeio ~ all_trips_v2$member_casual, FUN = median)
    all_trips_v2$member_casual all_trips_v2$duracao_passeio
## 1
                         casual
                                                         831
## 2
                         member
                                                         539
aggregate(all_trips_v2$duracao_passeio ~ all_trips_v2$member_casual, FUN = max)
    all_trips_v2$member_casual all_trips_v2$duracao_passeio
## 1
                        casual
                                                     2061244
## 2
                         member
                                                       89594
```

Média de duração de passeios por dia membros vs usuários casuais

```
# Ordenando dias da semana
all_trips_v2$day_of_week <- ordered(all_trips_v2$day_of_week, levels=c("domingo", "segunda-feira", "ter
aggregate(all_trips_v2$duracao_passeio ~ all_trips_v2$member_casual + all_trips_v2$day_of_week, FUN = m
##
      all_trips_v2$member_casual all_trips_v2$day_of_week
## 1
                           casual
                                                    domingo
## 2
                          member
                                                    domingo
## 3
                          casual
                                             segunda-feira
## 4
                          member
                                             segunda-feira
## 5
                          casual
                                               terça-feira
## 6
                          member
                                               terça-feira
## 7
                          casual
                                              quarta-feira
## 8
                          member
                                              quarta-feira
## 9
                          casual
                                              quinta-feira
## 10
                          member
                                              quinta-feira
## 11
                           casual
                                               sexta-feira
## 12
                          member
                                               sexta-feira
## 13
                           casual
                                                    sábado
## 14
                          member
                                                    sábado
##
      all_trips_v2$duracao_passeio
## 1
                         1633.6491
## 2
                          831.0463
## 3
                          1490.0468
## 4
                          721.9727
## 5
                          1286.5190
## 6
                          707.4686
## 7
                         1243.0783
## 8
                          710.8143
## 9
                          1284.2069
## 10
                          721.9113
## 11
                          1341.4274
## 12
                          733.6164
## 13
                          1605.9639
## 14
                          838.8955
```

Média duração de passeio por tipo de bicicleta e dia da semana


```
aggregate(all_trips_v2$duracao_passeio ~ all_trips_v2$rideable_type + all_trips_v2$day_of_week, FUN = m
## all_trips_v2$rideable_type all_trips_v2$day_of_week
## 1 classic_bike domingo
## 2 docked_bike domingo
```

```
## 3
                    electric_bike
                                                     domingo
## 4
                     classic_bike
                                               segunda-feira
                      docked bike
## 5
                                               segunda-feira
## 6
                    electric_bike
                                               segunda-feira
## 7
                     classic_bike
                                                 terça-feira
## 8
                      docked bike
                                                 terça-feira
## 9
                    electric bike
                                                 terça-feira
                     classic_bike
## 10
                                                quarta-feira
## 11
                      docked_bike
                                                quarta-feira
## 12
                    electric_bike
                                               quarta-feira
## 13
                     classic_bike
                                               quinta-feira
                      docked_bike
## 14
                                               quinta-feira
## 15
                    electric_bike
                                                quinta-feira
## 16
                     classic_bike
                                                 sexta-feira
## 17
                      docked_bike
                                                 sexta-feira
## 18
                    electric_bike
                                                 sexta-feira
## 19
                     classic_bike
                                                      sábado
## 20
                      docked bike
                                                      sábado
## 21
                                                      sábado
                    electric_bike
##
      all_trips_v2$duracao_passeio
## 1
                          1208.8029
## 2
                          3141.7058
## 3
                           952.5210
## 4
                           983.3772
## 5
                          3303.8398
## 6
                           781.9968
## 7
                           910.0892
## 8
                          2854.0780
## 9
                           717.9874
## 10
                           901.0409
## 11
                          2868.9331
## 12
                           720.0832
## 13
                           935.6433
                          2971.4789
## 14
## 15
                           738.6677
## 16
                           987.4033
## 17
                          2785.5459
## 18
                           794.3174
## 19
                          1216.0147
## 20
                          3148.2605
## 21
                           957.9425
```

Construindo vizualizações com ggplot2


Média de passeios por tipo de membro e dia da semana

'summarise()' has grouped output by 'member_casual'. You can override using the
'.groups' argument.



Média de duração de passeios por dia da semana

'summarise()' has grouped output by 'member_casual'. You can override using the
'.groups' argument.




Exportando para csv

write.csv(all_trips_v2, row.names=FALSE)

 $\label{locumentos} $$ `C:\Users\jande\Documentos\estudo_de_caso\divvy_trip_data_2022.csv", $$$

Compartilhar:

A ferramenta que escolhi para compartilhamento foi Qlik Sense Desktop pois já tive contato profissional com o mesmo. O Processo de ETL neste caso não envolveu ligações entre qvds diferentes por se tratar somente de um único arquivo csv.



Agir:

Conclusão

Membros anuais utilizam mais vezes o serviço porém membros casuais têm duração de passeios maior. Suas três principais recomendações com base em sua análise:

- Programa de fidelidade para membros casuais pelo tempo de uso.
- Promoções de início de semana pois o número de corridas diminui.
- Aplicar pesquisas de satisfação com clientes e fazer uma nova comparação com os novos dados.

Todas as recomendações devem ser trabalhadas junto as partes interessadas.